Universidad del Valle de Guatemala
Facultad de Ingeniería
Deep Learning y Sistemas Inteligentes
Sección 20

Mia Fuentes - 23775
Roberto Barreda - 23354

Propuesta: Predicción del consumo de combustible

Propuesta

Se propone desarrollar FuelWise AI, una aplicación web que predice el consumo de combustible de vehículos de gasolina a partir de series temporales de conducción. El modelo usa velocidad, revoluciones por minuto (RPM), carga del motor y consumo histórico para entrenar y comparar redes LSTM y GRU contra un método simple de referencia. Durante el trayecto, el sistema actualiza cada pocos minutos un pronóstico de consumo a corto plazo (L/h) con los datos disponibles hasta ese momento; no usa velocidad, RPM ni carga futuras. El total de litros y el costo del trayecto se calculan integrando estos pronósticos y se comparan con el consumo real. Se medirán MAE, RMSE, tiempo de inferencia y costo computacional de cada modelo.

Justificación

La predicción de combustible apoya dos decisiones de conductores y administradores de flotas: cuánto combustible reservar para un trayecto y cuándo reabastecer antes de que falte. Hoy estas decisiones se basan en el promedio histórico del vehículo o la ruta, lo que puede resultar en reservar de más o de menos frente al consumo real. Las redes LSTM y GRU capturan patrones de conducción que un promedio no captura, pero esa ventaja debe comprobarse frente al método de referencia. El proyecto comparará al menos dos versiones del modelo y traducirá la diferencia en error de predicción a diferencia en valor de negocio, sin afirmar ahorros no verificados.

Modelo de valor

El valor se mide por el costo de equivocarse en la reserva de combustible. Reservar de menos puede forzar un reabastecimiento de emergencia, con costo mayor al de repostar de forma planificada; reservar de más deja capital en combustible sin usar. La función de valor es: valor = ahorro por acierto − costo de déficit − costo de exceso. Los precios de combustible y el costo de un reabastecimiento de emergencia se tomarán de fuentes públicas y se documentarán como supuestos. Con esta función se construirá una curva de valor por nivel de error de predicción y se elegirá el margen de reserva que maximice el valor esperado.

Fuente de datos y evaluación

Se utilizará el conjunto de datos público Vehicle Energy Dataset (VED), recopilado con dispositivos OBD-II en 383 vehículos de Ann Arbor, Michigan, entre noviembre de 2017 y

noviembre de 2018; 264 son de gasolina. Los archivos contienen registros de velocidad (km/h), RPM, carga absoluta del motor, temperatura exterior y consumo de combustible (L/h), además de características del vehículo. Se revisará la cobertura y calidad de las mediciones y se filtrarán los registros de vehículos de gasolina. La división en entrenamiento, validación y prueba se hará por trayecto completo y antes de construir las ventanas temporales, para que ninguna ventana cruce entre conjuntos. El preprocesamiento se ajustará solo con el conjunto de entrenamiento, y la prueba se hará sobre vehículos no incluidos en entrenamiento, para medir qué tan bien generaliza el modelo. Fuente oficial: https://github.com/gsoh/VED (licencia Apache 2.0).

Referencias

Oh, G. S., LeBlanc, D. J., & Peng, H. (2022). Vehicle Energy Dataset (VED), a large-scale dataset for vehicle energy consumption research. IEEE Transactions on Intelligent Transportation Systems, 23(4), 3302–3312. https://doi.org/10.1109/TITS.2020.3035596

Oh, G. S. (s. f.). Vehicle Energy Dataset (VED) [Conjunto de datos]. GitHub. https://github.com/gsoh/VED

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder–decoder for statistical machine translation. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, 1724–1734. https://doi.org/10.3115/v1/D14-1179